

前沿 AI 的三张牌同时被翻开

NSA 已在用 Mythos · Opus 4.7 偷涨 47% · 开源再一次追平



五角大楼封杀、NSA 照跑

Axios 独家：美国情报机构正用 Anthropic Mythos 扫漏洞



Opus 4.7 隐性提价 35-47%

价格牌未动，tokenizer 切得更碎，长上下文成本飙升



Qwen 3.6 开源封顶

35B/3B 激活 MoE，SWE-Bench 73.4，按住 Google Gemma 4

五角大楼封杀的 AI，被自家情报机构 NSA 拿去扫漏洞



一张政府、两边立场

40

家机构
已获 Mythos 访问

12

家机构
Anthropic 公开

4/8

联邦上诉法院
驳回暂缓令

Axios 4/19 独家：NSA 已开始用 Anthropic 目前能力最强、最受限的前沿模型 Mythos Preview，对自有环境做漏洞扫描与利用链路推演。

关键冲突：

NSA 隶属国防部，而国防部 2 月把 Anthropic 列为 **"supply chain risk"**，要求军方承包商清除其软件——两者在法庭互告至今。

能源部、财政部同步申请准入；4/17 Amodei 亲赴白宫与幕僚长 Wiles、财长 Bessent 谈判。

信号 首个“具备攻击级网络能力”的前沿模型被政府实际部署。Pentagon 的封杀事实上名存实亡，Amodei 在白宫谈判桌上筹码明显增加。

卖鞋改卖 GPU : Allbirds 更名 NewBird AI , 当日股价飙 600%

 当日盘中峰值

+600%

BIRD 收盘仍涨 ~300%

\$50M

可转债融资

0 GPU / 0 电力

出售的只是 " 希望叙事 "

allbirds → **NewBird AI**

Y Combinator 扶持、DiCaprio 代言的 DTC 运动鞋新贵，2021 年上市后股价腰斩至几美分、市值不足 \$30M。

4/15 两条公告同时甩出：

① 鞋业资产出售给 American Exchange Group ; ② 签 \$50M 可转债转型 GPU-as-a-Service 云服务。

与 Core Scientific、Hut 8 等矿企转型不同——NewBird AI **没有任何数据中心、没有电力合同、没有 GPU**。Motley Fool 将其评为 "2026 年最离谱的 AI pivot"

信号 AI 算力泡沫向 " 壳资源 " 外溢的第一个消费品牌级信号——公开市场的风险偏好已经完全切换到 AI 基建叙事。

名义同价、实际涨 47% : Opus 4.7 的新 tokenizer 被抓了现行

Opus 4.6

1.00x

基线 tokenizer · \$5/M 输入 · \$25/M 输出

Opus 4.7 · 同一段文本

1.32x – 1.47x

Claude Code 32.5% / CLAUDE.md 44.5% / 技术文档 47%



@joozio 社区测算 (483 次真实请求) : 单次成本同步上涨 **+37.4%**。Finout 测算长上下文 Agentic workload 预算普遍上浮 35%+。Anthropic 未在迁移文档中披露 "同一段文本更贵"——下一步 OpenRouter 等网关大概率默认显示 "4.6 等效 token 数" 作为反制。

信号 前沿 LLM 第一次因 "tokenizer 偷换" 被集体盯上——价格稳定与成本稳定首次被迫分开讨论，Enterprise 合约续签难度将显著上升。

Qwen3.6-35B-A3B 开源：3B 激活参数按住 Google Gemma 4

Agentic Coding Benchmarks

SWE-Bench Verified



Terminal-Bench 2.0



73.4 这个数字即使放在 2024 年末，也会被视为 frontier tier。



Apache 2.0

35B

总参数 (MoE)

3B

每 token 激活参数

24GB

单卡即可流畅推理

~5pt

与 Sonnet 4.6 仅差距 5 分以内

HF / Ollama / GGUF 同步上架

信号 两周内两款中国开源模型跑赢同级闭源与 Google 开源旗舰——“用闭源才能做 coding agent”的护城河叙事正在断裂。

按训练进度收费：Grok 4.3 静默上线，\$300/月先吃半训练 checkpoint

参数规模 · Musk 亲自更正



已部署 ~0.5T

还差 ~5 天训到 1T

 \$300/月

SuperGrok Heavy 档位独享，\$30/月
普通订阅看得见、点不亮

 PDF / PPTX / Excel /
视频

原生生成，推理链路更细；模型选择器贴
Early Access 标

 滚动 checkpoint

半训练先付费压测，再对全量开放——
xAI 独创定价曲线

信号 "按能力" 定价第一次公开转向 "按训练进度"——\$300/月 Heavy 档位正从服务费变成训练赞助券。

把表演指令写进 prompt : Gemini 3.1 Flash TTS 登顶, SynthID 默认开启



TTS 盲测 Elo

1211

领先第二名 ~40 分

70+

语言

200+

音频标签



prompt 内直接写表演指令, 模型按标签切换

[whispering] You hear that? [fast] [Scottish accent]
No time – I'll explain once we're out. [breathing heavy]

- 200+ 标签覆盖情绪 / 口音 / 节奏 / 呼吸 / 停顿 / 共鸣位置
- 同一段对话里多说话人自动切换; 延迟维持 Flash 档位水准
- **SynthID 水印默认开启**——三大云巨头里第一个把 "可溯源" 做进商业产品

信号 在选举年 deepfake 成为头号议题的背景下, Google 把 "可溯源" 做成默认行为——为 YouTube/Vids 替换全球短视频配音链路埋了钉子。

ChatGPT 广告跨国开跑：两个月 \$100M ARR，\$8 Go 档位也吃广告

广告业务年化收入 (ARR)



\$100M

<2 个月 pilot · 线性外推年底破 \$600M



4/17 全量上线

覆盖市场：澳 · 新 · 加 (首个跨国 ads surface)

展示范围：

Free + Go ; Plus/Pro/Ent/Edu 无广告

定向方式：

contextual，不使用用户画像



600+ 广告主已接入；dismiss rate 低于社交平台基线；ChatGPT 7 亿周活已是一个不输 X/Reddit 的独立广告 surface。

\$8/月 Go 档位也吃广告——OpenAI 在用“超低价 + 广告”搬运所有对 Plus 嫌贵的用户进入商业漏斗。

信号 ChatGPT 从“订阅生意”向“广告 + 订阅双引擎”转身的分水岭——对 Google Search 与 Meta Ads 的冲击第一次变得可量化。

给 Agent 装长期记忆：Cloudflare Agent Memory 公测开放

传统做法

- 整段历史对话塞进 context window
- 工具输出、思维链反复充满窗口
- 开发者自建 vector db + RAG + TTL
- 长任务注意力分散 + 成本飙升

Agent Memory

- 托管服务自动抽取事实 / 决策 / 偏好
- 按相关性召回，只注入必要片段
- 架构从 3 层降到 2 层（省掉 memory 自建）



Agents Week 2026 · 压轴发布



Worker binding

一行代码接入，数据所有权归开发者



REST API

非 Worker 环境统一接入方式



并行发布

Artifacts（版本化存储）· Project Think（agent 框架）

信号 继 MCP 之后第二条可能的全行业 agent 侧基础设施事实标准——让独立开发者不再绑定任何 LLM 厂商的专属 memory。

今天 AI 圈在吵什么：三条最热话题与它们背后的冲突



#Tokenizergate

Opus 4.7 的 tokenizer 被抓现行

@joozio 的 token 计数贴被社区接力复现：同 prompt 吞 32.5-47% 更多 token，单成本涨 37.4%。Enterprise 合约讨论成下周主旋律。



#MythosGov

Pentagon vs. NSA 打同一家公司

Amodei 与 Susie Wiles、Scott Bessent 在白宫就政府使用 Mythos 的边界谈判；能源部、财政部同步申请准入。



#OpenSourceCoding

Qwen 3.6 + GLM-5.1 两周连击

SWE-Bench 73.4 / Pro 登顶——中国开源第二次在 coding agent 上把 Google 开源旗舰按在地上。

今天必须带走的 5 个信号

1



Pentagon 的封杀名存实亡

NSA 已在实操 Mythos ; " 国家安全 " 不再是单边否决前沿 AI 采购的万能理由。

2



价格稳定 $\neq$ 成本稳定

Opus 4.7 名义同价但 tokenizer 换血，同一段文本贵 35-47% 。

3



开源 coding 差距只剩身位

Qwen3.6 / GLM-5.1 连续两周踩中美闭源头上，" 非闭源不可 " 的叙事断裂。

4



AI 叙事再度外溢到壳资源

Allbirds 一句 GPUaaS 就涨 600% ; 下一轮概念炒作几乎确定会出现。

5



Agent 基建标准化提速

Cloudflare Agent Memory 把记忆做成托管服务——独立开发者不再绑定任何 LLM 厂商。