

2026 · 04 · 25 · 星期六

Anthropic 一周被两大云 \$650 亿 双向锁定

DeepSeek V4 用 1/10 KV cache 把 1M 上下文打成开源默认 · Claude 接 16 款 App 进 super-app · ICLR 把理论 ML 重新拉回聚光灯

\$ \$400 亿

Google 注资

\$3500 亿估值 · 5GW TPU 长约



1.6T MoE

DeepSeek V4 开源

1M 上下文 · \$1.74 / 1M tokens



16 款

Claude 接消费 App

Spotify · Uber · Booking

一句话定调今日 AI 行业

注资战、开源价格战、消费端入口战、工程透明度战 —— 同一周打响

01 资本面

Anthropic 史上首次被 AWS + Google Cloud 双向数百亿股权 + 长约锁定

02 技术面

DeepSeek V4 用 Hybrid Attention 把 1M token KV cache 砍至 10%

03 产品面

Claude 把 Spotify / Uber / TurboTax / Booking 16 款 App 一次接进对话

04 信任面

Anthropic 第一次正式 postmortem : Claude Code 三处工程事故公开

05 学术面

ICLR 2026 把 Outstanding Paper 给 Transformer 表达力的形式语言理论

两大 hyperscaler 同时押注 Anthropic

史上第一次 · \$100 亿即时到账，估值 \$3500 亿，\$300 亿与里程碑挂钩

GOOGLE 一笔注资上限

\$400 亿

vs Microsoft x OpenAI 此前最大单笔



Google

Alphabet · Sundar Pichai

4 月 24 日正式签字



5 GW × 5 年

Google Cloud TPU 算力长约

保留 '未来若干 GW 扩展' option



仅 4 天前：AWS \$250 亿

十年向 AWS 采购 \$1000 亿 + 算力

Trainium 锁到 2030 年代

信号：

Big Tech 共识 — 在 OpenAI 之外建立独立的前沿 AI 供应链已成战略必选

AWS 与 Google 在 4 天内对 Anthropic 投出了 \$650 亿

Anthropic run-rate 营收已突破 \$300 亿，是 2025 年底的 3.3×



4-20



AWS 追加 \$250 亿

\$50 亿即时



4-24



Google \$400 亿

\$100 亿即时



今日



估值压上 \$3500 亿

下一站 \$5000-8000 亿区间

Google 在 Anthropic 同时是三种身份



客户

Claude 是 Google Cloud 上的明星模型



投资人

\$100 亿股权 + \$300 亿里程碑追加



竞争对手

Claude 与 Gemini 在企业市场短兵相接

信号： OpenAI / Microsoft 独占模型 → 多源 hyperscaler 对冲模型，AI 基础设施竞争换骨架

DeepSeek V4 把 1M 上下文打成开源默认

无预热同步推送 V4 Pro + V4 Flash · 权重 MIT 协议放上 Hugging Face



1.6T

MoE 参数

激活 49B / token



1M

token 上下文

原生窗口 · 单次提交全代码库



27%

推理 FLOPs

vs V3.2 同长度



10%

KV cache

1M 上下文 · 同硬件 10x 并发



API 定价

\$1.74 in · **\$3.48** out per 1M tokens 比 Opus / GPT-5.5 同档便宜 5-10x

信号：中国开源阵营从 '追赶' 转为 '定义价格底线' — long-context agentic 工作流首次具备经济可行性

KV cache 砍 10× 才是 1M 上下文真正能落地的开关

不是把上下文从 32K 推到 128K 的边际改进，而是同硬件容纳 10× 并发或 10× 长度的结构突破



DeepSeek V4

MIT · Hugging Face

Hybrid Attention Architecture

CSA

Compressed Sparse Attention

快速筛掉绝大部分远距离 token



HCA

Heavily Compressed Attention

对剩余 token 做高压压缩深度交互



MMLU

88.4%



Humanities-X

92.1%



API 价格

\$1.74



权重协议

MIT

信号： OpenRouter 上中国模型连续 5 周以 4:1 token 消费量碾压美国模型，本周拐点更深

Claude 把自己变成日常 super-app 的 '前门'

一次接入 16 款消费级 App · Free / Pro / Max 全 plan 同步上线



出行 / 本地

Uber · Uber Eats · Resy · AllTrails



内容 / 娱乐

Spotify · Audible · StubHub



购物 / 服务

Instacart · Taskrabbit · Thumbtack



旅行 / 财务

Booking · TripAdvisor · Viator · TurboTax · Credit Karma



隐私正面对标 ChatGPT

数据不进训练集 · 跨 App 不互通历史 · '下单 / 付款' 类操作必二次确认

信号： Claude 第一次走出代码 / 写作专业边界，正面对标 OpenAI 'Apps in ChatGPT'

Claude Code' 变笨' 是三起真实工程事故叠加

Anthropic 第一次正面承认、点名时间、点名根因 · API 全程未受影响



March 4

推理预算被砍

默认 reasoning effort 被悄悄下调，chain-of-thought 步骤变浅



March 26

缓存丢推理历史

缓存层 bug 让模型在跨 tool call 时丢弃推理上下文 — 最直接的 '失忆' 根因



April 16

回复硬限到 25 字

系统 prompt 改动把 tool call 之间的回复硬限 25 字 — IDE 体验显得敷衍



全部已于 April 20 修复

API 用户全程不受影响 · 仅 Pro / Code 客户端命中

信号：Anthropic 从 '静默更新' 转向透明工程沟通 — 给 OpenAI / Google 同行施加披露压力

ICLR 把理论 ML 重新拉回聚光灯

过去 5 年 Outstanding Paper 几乎被 scaling / agent 工程论文垄断 · 2026 首奖给了一篇形式语言理论



OUTSTANDING #1 · 理论

Transformers are Inherently Succinct

Pascal Bergsträßer · Ryan Cotterell · Anthony Widjaja Lin

从形式语言理论给 Transformer 表达力建立 succinctness 形式化框架 — 证明 Transformer 比 RNN / Markov 链有可证明的 '指数级简洁'。



OUTSTANDING #2 · 评测

Dissonant Gap in Multi-Turn Evaluation

ICLR 2026 Outstanding Paper Committee · 数十位作者

训练数据分布 vs 真实 deployment 多轮分布的失配 — 提出可扩展、贴近真实使用场景的多轮评测方法。

Rio de Janeiro · 4·23-4·27 · 3,500+ 接收论文 (接收率 31.4%) · 同步亮相 Google TurboQuant · DeepMind RNN 大规模训练新架构

AI 圈今天在讨论什么

围绕 Anthropic 双重输血 + DeepSeek 同日开源，三个话题最热

01



\$650 亿一周 — Anthropic 还撑得住一致性吗？

@karpathy / @ylecun / @alexandr_wang 都在追问：估值压到 \$5000-8000 亿后，研究优先级会不会被产品化吞没。

02



DeepSeek 把 1M 上下文价格按到 \$1.74

Hugging Face / OpenRouter 社区当日观察：API 价格被中国开源连续第 5 周拉低，'闭源高价模型'正在被结构性挑战。

03



Anthropic postmortem 是否会成行业新规范

@JeffDean / @JonathanRoss321 评论：透明披露具体 bug 时间线在前沿模型领域罕见 — 给 OpenAI / Google 施加披露压力。

信号： 当日舆论焦点：资本浓缩 + 开源价格底线 + 工程透明度规范化 三件事同时发生

一组数字读懂今天

把 5 篇报道压成 6 个数据点

\$ \$650 亿

Anthropic 一周吸金

Google \$400 亿 + AWS \$250 亿

👑 \$3500 亿

Anthropic 估值

下一站 \$5000-8000 亿区间

∞ 1M

DeepSeek V4 上下文

首次 MIT 开源完全开放

💾 10%

KV cache 用量

1M 上下文 · 同硬件 10× 并发

🛒 16 款

Claude 接消费 App

Spotify · Uber · TurboTax · Booking

🎓 31.4%

ICLR 2026 接收率

3,500+ 论文 · Rio de Janeiro

今天必须知道的 5 件事

把今日 briefing 浓缩成 5 行高密度信息

01 🏠 Anthropic 进入多云时代

Google \$400 亿 + AWS \$250 亿一周内同时落地，OpenAI / Microsoft 独占模式被打破。

02 🔒 1M 上下文不再是闭源专属

DeepSeek V4 用 Hybrid Attention 把 KV cache 砍到 10%，并以 MIT 协议把权重放上 Hugging Face。

03 🛒 Claude 走出代码 / 写作专业边界

16 款消费 App 接入对话 super-app，正面对标 OpenAI 'Apps in ChatGPT'，并用 '数据不训练' 区隔。

04 🛠️ 前沿模型工程透明度规范开始建立

Anthropic 公开 Claude Code 三处具体 bug 时间线 + 根因，给 OpenAI / Google 施加披露压力。

05 🎓 理论 ML + 多轮评测重新上桌

ICLR Outstanding Papers 把 Transformer 表达力理论与多轮评测拉回主流议题，benchmark 失真共识形成。

一句话总结今天

资本、技术、产品、信任 四条护城河，
在同一周里被同时改写。

明天继续 — 7:36 AM UTC

SOURCES

Bloomberg · TechCrunch · CNBC · Fortune · Engadget · 9to5Mac · Hugging Face · ICLR Blog · Anthropic Engineering Blog