

📅 2026 年 5 月 18 日 · 每日科技 & AI 简报

AI 安全护栏，第一次被现实正面打穿



Mythos 6 天造出可用 macOS 内核 exploit，上线首日即遭无授权访问



受限前沿安全模型 → 6 天写出绕过 Apple M5 的内核 exploit



SpaceXAI 合并 4 个月走掉 50+ 研究员，预训练团队仅剩个位数



DeepMind / OpenAI / Anthropic 罕见联署：对齐范式要换

6 天，一枚绕过 Apple M5 内存防护的可用内核 exploit



受审受限模型，做出了真实战果

Palo Alto 安全公司 Calif 借助 Anthropic 受限的 Claude Mythos Preview，4-25 发现 macOS 漏洞，到 5-1 仅 6 天就写出绕过 Apple M5「内存完整性强制」的可用内核 exploit。

Anthropic 始终将 Mythos 定性为「强到不能公开发布」，仅通过 Project Glasswing 向少数受审伙伴开放、且限防御用途——这套叙事被打穿。

「公开博客如一颗深水炸弹般穿过安全社区」

6

天

从发现漏洞到可用内核 exploit

21/41

V8 引擎漏洞

达成完全任意代码执行

模型没被攻破，护栏却在供应链环节就被绕过



4-7 上线当天即遭未授权访问

并非模型被攻破：一名第三方承包商凭证，叠加 AI 招聘创业公司 Mercor 的数据泄露，再加上对 URL 规律的猜测，让一批 Discord 用户在「第一天」就摸进本应严格受控的 Project Glasswing 预览环境。Anthropic 重申 Mythos 不会面向公众开放。



受限发布

定性为「强到不能公开发布」，仅 12 家首发伙伴 + 40 多家受审机构



护栏被绕

薄弱点在访问控制与供应链，而非模型缺陷



评估佐证

叠加英国 AI Security Institute 对 Mythos 攻防能力的评估



信号

受限发布 + 受审伙伴的治理护栏，在供应链环节就可能被绕过——进攻能力扩散正在发生，而非风险预测。

SpaceXAI 合并即失血：4 个月走掉 50+ 研究员



出血集中在最难补的能力线

SpaceX 2 月收购 xAI、5 月重新品牌为 SpaceXAI 并换帅。coding、world models、Grok voice 团队均遭重创，预训练团队削到个位数。

离职归因：Musk 高压文化、不切实际的训练 deadline（被指导致「在 Grok 上偷工减料」），及临近 SpaceX IPO 的套现预期。

合并公布后立即又有 11 人离职，含两名联合创始人

50+

自 2 月起累计
离职研发人员

11

去了 Meta
Superintelligence Labs

7

加入 Mira Murati 的
Thinking Machines

Runway 押注「视频即世界模型」，正面刚 Google

从「服务影视」整体转向世界模型

2025 年 12 月发布首个世界模型，年内将再发一个；2025 年已成立机器人部门做真实世界测试与部署。

核心论点是路线之争：当行业押注语言模型，Runway 押注「视频」才是突破数据偏置、通往更强通用智能的路径，正面对标 Google 的 Veo / Genie。

「要走得更远，必须用偏置更小的数据」—— 联合 CEO

\$53 亿

最新估值（外部者 + scrappy 文化）

\$4000 万

Q2 2026 新增 ARR · 为非共识路线投票

三大对手实验室罕见联署：对齐要从「别作恶」升级



Positive Alignment（积极对齐）

DeepMind、OpenAI、Anthropic 与多所高校联署 arXiv 预印本。三家通常彼此竞争的前沿实验室，罕见地在对齐范式上走到一起。主张：以拒答、过滤为中心的防御式对齐仍可能产出操纵性、谄媚的系统，应转向主动培养智慧、自主、求真与社会协作。

「守规却不智慧」概括当前系统的局限

技术

预训练阶段就 curate 亲社会语料；带显式原则的 Constitutional AI；持久记忆与长期个性化

治理

polycentric 多中心治理，让不同社区对 AI 行为有本地控制权

评测

以认知谦逊、平衡推理、情绪韧性为指标的「繁荣导向」基准；价值多元



今日关键数字

一屏看懂 2026-05-18 的四条主线

6 天

受限模型造出 macOS 内核 exploit

21/41

V8 漏洞达成完全任意代码执行

50+

SpaceX AI 自 2 月起离职研究员

18

去 Meta(11) + Thinking Machines(7)

\$53 亿

Runway 估值，押注世界模型

3 家

DeepMind/OpenAI/Anthropic 联署对齐



主题透视：四条新闻，三股暗流



治理护栏正在「先扩散后修补」

Mythos 既证明前沿进攻能力已可 6 天落地，又暴露受限发布在供应链 / 访问控制环节的脆弱——危险论从论文走进现实。



前沿人才战进入抽血阶段

Meta 与 Thinking Machines 直接从 SpaceXAI 挖走预训练 / world models 骨干，能力差距通过人事流动被快速放大。



路线分叉：语言 vs 世界模型

Runway 以真实营收为世界模型路线背书，与 Google Veo/Genie 正面竞争；「语言模型即一切」开始被有钱的非共识者挑战。



对齐议程从防御转向积极

三家对手实验室联署，把对齐目标从「别作恶」抬到「让人活得更好」，将影响训练数据、评测与监管话语。

今日必读 · 5 个要点

1 「6 天造 macOS 内核 exploit」是危险论第一次落到可复现现实，操作系统与关键基础设施的修补窗口正在收窄。

2 Mythos 上线首日失守证明：模型再强，治理护栏也可能在承包商凭证 / 供应链处被绕过。

3 SpaceXAI 4 个月走 50+ 人，预训练等最难补的能力线被 Meta、Thinking Machines 直接抽血。

4 Runway 以 \$53 亿估值 + 真实 ARR 为「视频即世界模型」背书，与 Google Veo/Genie 路线开战。

5 DeepMind/OpenAI/Anthropic 罕见联署「积极对齐」，对齐目标从防止有害转向主动支持人类繁荣。