



2026 年 5 月 19 日 · 星期二

Google 把 Gemini 搬进操作系统

模型趋于平价，护城河正快速迁向 OS 与 agent 层



Google I/O 2026 : Gemini 下沉为系统级 agent 层，新旗舰仅追平 GPT-5.5、落后 Claude Mythos



Cursor Composer 2.5 : 开源中国底座 + 调优，基准追平 Opus 4.7，价格只要零头



Musk 以「时效」败诉 · Meta 盈利新高仍裁 8000 人 · Nvidia 对华收入按零计



前沿与构建者

模型平价化，竞争转向系统分发与企业落地

Gemini 从聊天框下沉为「系统级 agent 层」

Google I/O 2026 : 主线从「发新模型」转向「让 Gemini 替你干活」

≈ GPT-5.5

新旗舰定位，落后 Claude Mythos

~90%

Flash 编码 / 推理达 GPT-5.5 能力

1/15–1/20

Flash 相对成本



Gemini Intelligence 读屏上下文、跨 Gmail/Calendar/Drive 自动完成多步任务



Gemini Spark 常驻个人 agent：清理收件箱、生成会议简报与个性化新闻



Android XR 眼镜 Samsung/XREAL/Warby Parker 等首次现场上手，Gemini 驱动实时翻译

信号 真正信号在战略转向——Google 默认这代旗舰只能与 GPT-5.5 同档，于是用十亿级分发与系统整合对冲模型差距。

构建者



开源中国底座 + 调优 = 前沿水平、零头价格

Cursor Composer 2.5 : 不换底座 (Moonshot Kimi K2.5) , 押注后训练而非自研底座

79.8%

SWE-Bench Multilingual

63.2%

CursorBench v3.1

\$0.5 / \$2.5

每百万 token 输入 / 输出



训练打法 相比上代用 25x 合成任务，85% 算力预算投入额外训练与 RL



对标结果 基准达到与 Opus 4.7、GPT-5.5 同档，长编码任务更稳



成本结构 相对前沿闭源旗舰只是零头，推理成本降约一个数量级

信号 编码模型平价化的又一记重锤——开源底座 + 应用层后训练正从下方持续掏空最赚钱的 agent 场景。

Big-4 把全员标准化到单一前沿模型

Anthropic × PwC 扩大战略联盟，Claude 深嵌咨询交付 workflow

数十万

全球员工逐步铺开范围

3 万

计划培训认证 PwC 专业人员

美国先行

Claude Code + Cowork 首发团队



部署范围 先美国团队上线 Claude Code 与 Cowork，再扩至全球员工



联合机构 双方共建联合卓越中心，沉淀方法论与行业方案



标志意义 一家 Big-4 把单一前沿模型作为全员生产力底座标准化

信号 对 Anthropic 是把前沿模型变现为「企业全员标准件」的关键分发管道——直达 PwC 覆盖的全球大客户。

编码 agent 首次正式打进 on-prem 企业

OpenAI × Dell : 把 Codex 带入混合云与本地数据中心

-  **部署形态** Codex 从纯云 API 扩展为可在客户自有机房内运行
-  **目标客户** 面向合规约束、数据不能出域的金融、政府、医疗大客户
-  **落地通道** Dell 提供硬件与企业落地渠道，正面进入 Anthropic 同一战场
-  **竞争转向** 编码 agent 之争从「模型谁更强」转向「谁能进客户机房」

信号 本地化部署是把编码 agent 卖进受监管大企业的关键一跃——这些客户预算最厚、却最不能用纯云 SaaS。

今日 X / AI 社区焦点

热度由编码模型平价化、Gemini 悬念与 Musk 判决三条线索主导



编码模型平价化

Cursor Composer 2.5 以开源 Kimi K2.5 底座追平 Opus 4.7 / GPT-5.5、价格仅零头——「自研基座是否还必要」成社区主轴讨论。



Gemini Omni 悬念

5-11 泄露的 Gemini Omni 内测视频被评多维超越 Veo 3.1，I/O 2026 揭晓前持续刷屏，期待与质疑并存。



「Calendar technicality」

Musk 败诉后在 X 把判决定性为「日历技术性」并扬言上诉，相关帖文引发大量转评与法律解读。



行业要闻

诉讼、裁员、芯片——结构性变化在加速

陪审团 2 小时以「时效」判 Musk 败诉，实体争议被悬置

Musk v. Altman 加州联邦法院案了结，法官当庭采纳咨询裁决

~2 小时

9 人咨询陪审团议事时长

\$1800 亿

落空的「不当所得」诉求

留任

Altman / Brockman 不被罢免



败诉理由 认定 Musk 2024 年起诉已超 3 年时效，未触及实体是非



悬置问题 「是否背信公益慈善信托」被法院刻意搁置未裁



后续 Musk 称判决为「calendar technicality」，明确将上诉

盈利创新高仍裁 8000 人，全员重组进 AI 「pod」

Meta 自 5-20 起结构性裁员，而非绩效或业绩驱动

8,000

裁撤岗位（约全球 10%）

~14,000

含撤回待招的总收缩编制

\$2,010 亿

年营收（+22% YoY）



重组方向 团队整体编入 Alexandr Wang 的 Superintelligence Labs



强烈反差 动刀不在低谷而在创纪录财务期，下半年还有第二轮



资本流向 今年 AI 基建资本开支 \$1,150–1,350 亿，预算向算力倾斜

H200 解禁 $\neq$ 中国市场开放，今年对华收入按零计

黄仁勋访华后首度公开表态：闸门握在北京而非华盛顿

7.5 万颗

美方对每家中企的许可上限

零

至今实际交付 / 今年对华收入计入

~10 家

获 H200 出口许可的中国大厂



黄仁勋表态 「中国政府须决定要保护多少本土市场……市场早晚会开」



现实层面 未与中方当面谈 H200；中厂转向国产替代（腾讯 / 阿里自研）



变量转移 拿到美方许可 $\neq$ 拿到中国市场，准入决策权移至北京

今日要点

 **模型平价化、护城河转移** 旗舰能力趋同，竞争从「最强模型」切到 OS、agent 与企业分发（Google / Cursor 同向）。

 **编码 agent 大战转向落地** Anthropic×PwC 全员标准化、OpenAI×Dell 进 on-prem——同一企业战场正面交锋。

 **开源底座 + 后训练逼近闭源** 中国开源权重经合成数据与 RL 调优可贴前沿，推理成本降约一个数量级。

 **Musk 案以时效收场** OpenAI 营利化重组司法上「存活」，但「是否背离初心」被悬置，上诉延续不确定性。

 **高利润大裁员成常态** Meta 盈利新高仍裁 8000 人；Nvidia 对华关键变量从美方管制移到北京准入。