

每日 TECH & AI 简报

2026 年 7 月 26 日 · 星期日

旗舰智能，半价开卖 AI 竞争主战场移向「推理经济学」



Anthropic Opus 5 逼近 Fable 5，价格却只有一半



Etched 敲定 3 亿美元 C 轮，估值七个月翻倍至 103 亿



Intel 靠 AI 单季营收暴涨 25%，创 15 年最快增速

今日速览

6 条主线 · 一图看懂



前沿模型

Opus 5 近旗舰能力砍半价，新增「努力档位」旋钮



推理芯片

Etched 估值翻倍破 103 亿，红杉赌 Transformer 专用 ASIC



分离式推理

AMD × Cerebras 拆分 prefill/decode，每瓦 token 翻 5 倍



芯片财报

Intel AI 翻身，数据中心 AI +59%，capex 破 200 亿



AI 硬件

三星首款 Galaxy Glasses，把 AI 助手「戴上脸」



主权 AI

日本 44 家企业组 Noestra，抱团造「物理 AI」

近旗舰能力砍到半价，还给用户装了「努力档位」旋钮

1/2 成本

逼近旗舰 Fable 5 智能，价格只需一半

0.5%

CursorBench 上与最强 Fable 5 的差距

3×

ARC-AGI 3 解题得分为竞品三倍



新增「努力档位」(effort) 开关

用户可显式选择 low / medium / high 思考量，在「更聪明」与「更省 token、更快、更便宜」之间自行取舍，另配 2.5× Fast mode。

定价维持每百万 tokens 输入 \$5 / 输出 \$25 不变——不涨价换来一次能力跃迁，即刻登陆 API、Claude.ai、Claude Code。

专用推理芯片豪赌落定：七个月估值翻倍破 103 亿

\$10.3B

投后估值，去年 12 月还只有 50 亿

\$300M

本轮 C 轮融资额，红杉领投

≈20×

Sohu 推理吞吐相对英伟达 H100

\$1B+

已签客户合同金额



把 Transformer 焊进硅片的赌注

三位哈佛辍学生 2022 年创办；核心产品 Sohu 是台积电 4nm 上、把 Transformer 架构直接固化进硅片的专用 ASIC。参投方含 a16z、Jane Street、SK Hynix，天使名单还有 Peter Thiel、Andrej Karpathy、Dylan Field。

「拆开来打」英伟达：分离式推理架构



AMD Helios · 高吞吐 Prefill

机架级系统充当「高吞吐 prompt 引擎」，批量处理海量复杂请求，负责计算密集的预填充阶段。



Cerebras WSE · 超低延迟 Decode

晶圆级引擎专司「解码」环节，以超低延迟实时吐出 token，主打带宽敏感的回归生成。

5×

每瓦每秒 token 吞吐最高提升

较仅用 Cerebras WSE 配置，2026 下半年经 Cerebras Cloud 先行上线

信号

prefill 与 decode 算力/带宽特征天差地别，「组合拳」在推理层向英伟达一体化方案发起挑战。

掉队者靠 AI 翻身：单季营收暴涨 25%，创 15 年最快

+25%

营收 161 亿美元，15 年多来最快增速

+59%

数据中心 AI 业务同比暴增，收入 63 亿

41.8%

非 GAAP 毛利率，高出指引 280bp

>\$20B

2026 capex 由约 180 亿上调



AI 相关业务约占总营收七成

CEO 陈立武（Lip-Bu Tan）称这是公司 15 年多来最快增速。上调的资本开支主要投向 Intel 3、18A 与 18A-P 制程产能，并暗示 2027 年投入可能再度显著抬升。

手机厂商集体「上脸」：三星端出首款 Galaxy Glasses



Galaxy Glasses

三星首款 AI 智能眼镜，主打把 AI 助手「戴上脸」。分别与 Warby Parker、Gentle Monster 推两个时尚联名款。

价格、上市地区与发售日期尚未公布。



Galaxy Z Fold8 Ultra

「一机三用」：展开 8 英寸主屏，外屏 6.5 英寸当普通手机。

2 亿像素主摄 + 3 倍光变长焦。

起售价 **\$2,099.99 (256GB)**，美国 8 月 7 日开卖。

44 家企业抱团造「主权物理 AI」，把工业数据攥在自己手里



自主可控算力

本地掌控的计算资源，减少对外国 AI 算力依赖



专有工业数据

各家积累的现场制造数据，构成差异化护城河



机器人工艺经验

深厚的机器人与制造工艺 know-how



与政府端 FRONTia 一上一下呼应

政府出资金与算力底座（五年 1 万亿日元、采购英伟达 Rubin GPU），产业联盟出数据与落地场景。

「推理经济学」成为 AI 竞争新主战场



模型侧：按需付费

Opus 5 用「努力档位」把算力当旋钮，让每一次调用都能匹配任务价值——不再为简单请求付旗舰价。



芯片侧：专用突围

Etched 把 Transformer 焊进硅片、AMD × Cerebras 拆分 prefill/decode，都在绕开通用 GPU 抢推理层。



需求侧：全员加码

Intel 数据中心 AI +59%、capex 破 200 亿，印证军备竞赛已从模型公司蔓延至每家芯片与代工厂。



今日 5 个关键点

1

Opus 5 不涨价、能力跃迁

近旗舰智能砍到半价，新增 low/medium/high 「努力档位」，把近旗舰能力变成日常口粮。

2

专用推理芯片拿到资本背书

Etched 估值七个月翻倍破 103 亿、红杉领投、SK Hynix 入股，Sohu 宣称 20× H100 吞吐。

3

分离式推理成工程新范式

AMD × Cerebras 拆分 prefill/decode，每瓦 token 翻 5 倍，组合拳挑战英伟达一体化方案。

4

Intel 靠 AI 强势翻身

单季营收 +25% 创 15 年最快，数据中心 AI +59%，capex 破 200 亿并预告 2027 再加码。

5

AI 硬件与主权 AI 齐头并进

三星首款 Galaxy Glasses 把助手「戴上脸」；日本 44 家企业抱团造「主权物理 AI」。