

算力军备白热化，成本纪律登场



AMD 数据中心营收 +107%，从 Nvidia 手中抢下 Anthropic 2GW 大单




Anthropic 三线出击：\$10B 挪威算力 + 自研芯片，系统性对冲 Nvidia



微软给工程师装上 token 预算闸门——AI 进入‘精算单位经济学’阶段

七条要闻：算力、芯片、判例与成本纪律



AMD 财报翻倍

数据中心 +107% 至 \$6.7B，拿下 Anthropic 2GW MI450



Anthropic 押注挪威

6 年 \$100 亿锁定 121MW 水电算力，交易对手成立仅半年



Anthropic 自研芯片

组建定制芯片团队，传洽谈三星代工，垂直整合到底



AI 智能体第一判例

第九巡回撤销亚马逊禁令：访问的是用户，不是 AI



Meta 入局编程

首款 Muse Code 上线，低价对标 Claude Code 与 Codex




Palantir 暴涨

营收 +93%，‘主权 AI’需求推动股价单日跳涨 29%

AMD Q2 2026 财报 · 8月4日

AMD 数据中心营收翻倍，从 Nvidia 嘴里抢下 Anthropic



+107%

数据中心营收同比

\$6.7B

该分部单季营收

\$2.1B

由亏转盈的经营利润

2 GW

Anthropic MI450 大单

第二增长曲线终于兑现

一年前数据中心分部还经营亏损约 2 亿美元，如今单季营收 67 亿美元、经营利润 21 亿美元。AMD 把只是‘PPT 叙事’的 Instinct 系列，做成了实打实赚钱的业务。

撕开 Nvidia 的垄断裂缝

被视为‘Nvidia 铁杆客户’的 Anthropic，主动把最高 2GW 算力押注给 AMD Helios 机架中的 MI450，是对其软硬件成熟度的公开背书，也让 AMD 拿下头部前沿实验室的旗舰订单。

信号 Nvidia 近乎垄断的训练 / 推理格局出现实质裂缝：算力供应商多元化正从口号走向签约，议价权开始向买方微妙回移。

Anthropic × Volta · 8月4日

把 100 亿美元押给一家半年前才成立的公司



\$10B

6 年算力协议总额

121 MW

挪威 Vera Rubin 算力

< 6 个月

Volta 成立时间

算力饥渴到‘来者不拒’

标的是挪威 Tydal 园区、由比特币矿企 Bitdeer 运营、靠水电供能的 121MW 算力，分两期在 2026 年底与 2027 年 3 月交付。交易对手 Volta 由前 Brookfield 高管今年初才创立，成立不到半年即拿下百亿订单。

AI 算力正被彻底金融化

这笔交易首次为 Nvidia 生态引入 JPMorgan 信贷背书——大行为 GPU 租赁提供融资担保。长租约 + 矿场改造 + 大行兜底，一套层层转移重资产风险的融资工程正在成型。

⚡ 信号 前沿实验室对算力的渴求与 AI 基建融资化并行推进：金融机构给算力兜底，正成为 AI 基建的新范式。

Anthropic 开始自己造芯片：垂直整合到芯片层



采购 · AMD

2GW MI450 大单



扩容 · Volta

\$100 亿挪威算力



自研 · 芯片

组队 + 传洽三星代工

为什么要自己造芯片？

目标是把模型与硬件放在一起协同设计 (co-design)，在推理成本与吞吐效率上获得结构性优势——这正是 Google(TPU)、亚马逊 (Trainium/Inferentia) 已走通的路。短期靠采购多元化对冲 Nvidia 依赖，长期靠自研芯片压低单位 token 成本。

第九巡回上诉法院 · 8月4日

‘是用户在访问，不是 AI’：AI 智能体的第一道判例



法院撤销亚马逊禁令

亚马逊曾以 Perplexity 的 Comet 购物智能体‘未经授权访问服务器、违反 CFAA’为由取得初步禁令。第九巡回法院推翻了它，核心论证：真正登录并访问服务器的是用户本人，而非 Perplexity。

刻意留白，范围狭窄

法院援引‘宽大解释原则’在 CFAA 歧义时作出免责解读，并罕见承认‘几乎没有现成判例可界定 AI 智能体的责任归属’，同时强调裁决范围狭窄、相关法律仍将持续演变。



“users, not Perplexity, access third-party servers under the CFAA”

案件发回旧金山联邦地区法院续审；亚马逊的商标及州法主张仍存续，可申请重审或上诉至最高法院。

 **信号** 美国司法首次就‘AI 智能体代表用户访问网站是否违法’给出方向：短期利好浏览器 / 代购 / 自动化智能体公司，但博弈才刚开始。

Meta · 8月5日

Meta 也来抢编程智能体的饭碗：Muse Code 上线



\$1.25

输入 / 百万 token

\$4.25

输出 / 百万 token

第 3 家

入局巨头 (继 Claude / Codex)

从‘提供模型’到‘提供智能体’

继 7 月以 Muse Spark 1.1 切入编程模型后，Meta 拿出成品级编程智能体 Muse Code，能自主写码、改码。开发者按量付费 (pay-as-you-go) 接入，定价沿用 Muse Spark 1.1。

以价换量、以量换生态

价位明显低于 Claude、GPT 旗舰。Anthropic 靠 Claude Code 拿下开发者心智、OpenAI 靠 Codex 绑定企业，Meta 带着低价与庞大开源社区入局，试图两端同时撬动份额。

⚡ 信号 编程是 AI 最能直接变现、竞争也最惨烈的场景：Meta 的低价会压低价格中枢，倒逼头部实验室在性能溢价与价格战之间取舍。

MICROSOFT 内部备忘 · 8月4日

微软给工程师的 AI 用量装上‘预算闸门’



“刷 token(tokenmaxxing) 不是我们要优化的方向——我希望所有人聚焦于真正能为客户和业务带来成效的产出。”

— Jay Parikh，微软负责工程的执行副总裁



设预算目标

各业务部门执行 AI token 预算目标



自查用量

员工可追踪个人 token 消耗



默认降级

内部默认模型切到更便宜的 GPT-5.6

导火索：不少工程师每月 token 花费从数百到数千美元不等。

信号 AI 从‘不计成本抢采用’进入‘精算单位经济学’：连自己就是模型供应商的微软都要给内部用量设闸门——AI 本身也得降本。

Palantir Q2 2026 财报 · 8月3日

‘主权 AI’把 Palantir 送上天：营收 +93%，股价跳涨 29%



+93%

总营收同比至 \$1.94B

+149%

商业业务至 \$764M

+90%

政府业务至 \$809M

+29.5%

财报后股价单日涨幅

两条腿同时狂奔

总营收 19.4 亿美元、同比 +93%，轻松超过约 18 亿美元的市场预期。商业与政府业务双双高速增长，消息一出股价单日跳涨约 29.5%。

‘主权 AI’兑现为真实订单

各国政府与大企业越来越希望在自己可控的环境里部署 AI，而非把关键数据托付给外部大模型。Palantir 的 Foundry/AIP 恰好卡在‘把大模型接入受管、可审计 workflow’这个位置。

信号 在多数 AI 公司还在烧钱抢份额时，Palantir 证明‘把 AI 装进政府与大企业受管 workflow’是一条已跑通、且高速增长的变现路径。



AI 社区热议 · Trending on X

今天开发者与投资圈在争论什么



#tokenmaxxing

微软那句‘刷 token 不是优化目标’刷屏，社区激辩：AI 生产力该按产出算，还是按用量算？成本纪律成新共识。



#MI450

AMD 拿下 Anthropic 2GW 大单引爆讨论，‘Nvidia 护城河是否被高估’再度成为多空交锋焦点。



#Alagents

第九巡回撤销亚马逊禁令后，法律与开发者圈热议：智能体访问网站的责任边界到底在谁？



#codingwars

Meta 低价 Muse Code 入场，编程智能体价格战成热帖：性价比 vs 性能溢价，开发者站哪边？

注：热点主题由当日要闻与社区讨论综合归纳。



KEY TAKEAWAYS

今天最该记住的 5 件事



1 Nvidia 垄断出现实质裂缝

AMD 数据中心营收翻倍且拿下 Anthropic 2GW MI450 大单，算力多元化从口号走向签约。



2 AI 算力被彻底金融化

Anthropic \$100 亿押注成立半年的 Volta，JPMorgan 首次为 Nvidia 生态算力租赁背书。



3 前沿实验室垂直整合到芯片

Anthropic 采购 + 扩容 + 自研三线并进，长期目标是压低单位 token 成本。



4 成本纪律取代无限投入

微软给 token 用量设预算闸门，AI 进入‘精算单位经济学’——AI 本身也要降本。



5 变现与判例双双落地

Palantir 靠‘主权 AI’营收 +93%；第九巡回为 AI 智能体访问网站划出第一道判例。